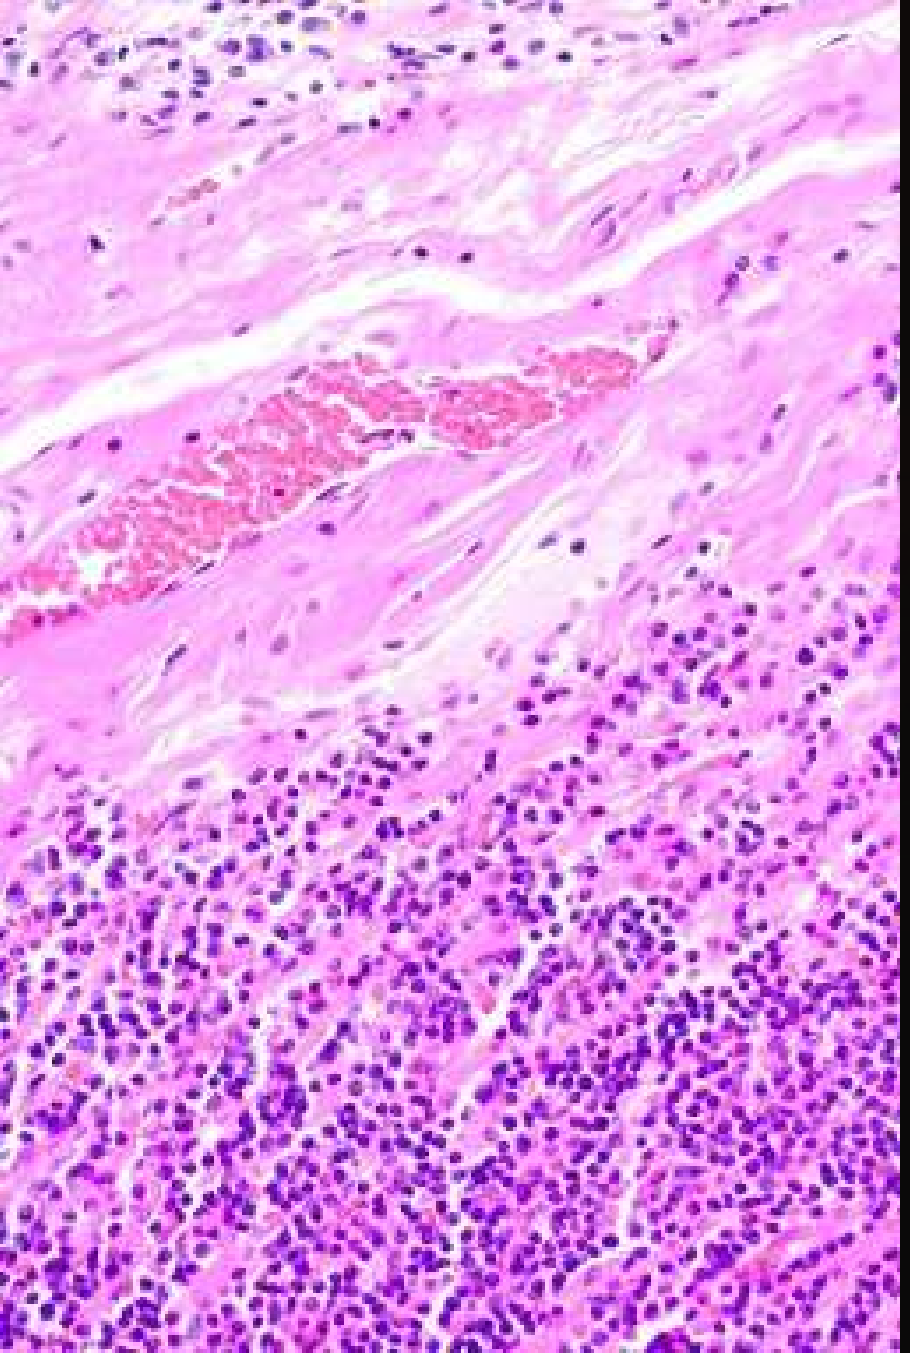

Deep Learning sur PATHMNIST

Analyse comparative de modèles de classification — MLP, CNN, ResNet18 et Vision Transformer — appliquée aux images histopathologiques colorectales.

IMAGERIE MÉDICALE | APPRENTISSAGE PROFOND | CLASSIFICATION

Made with GAMMA

Le Dataset PATHMNIST

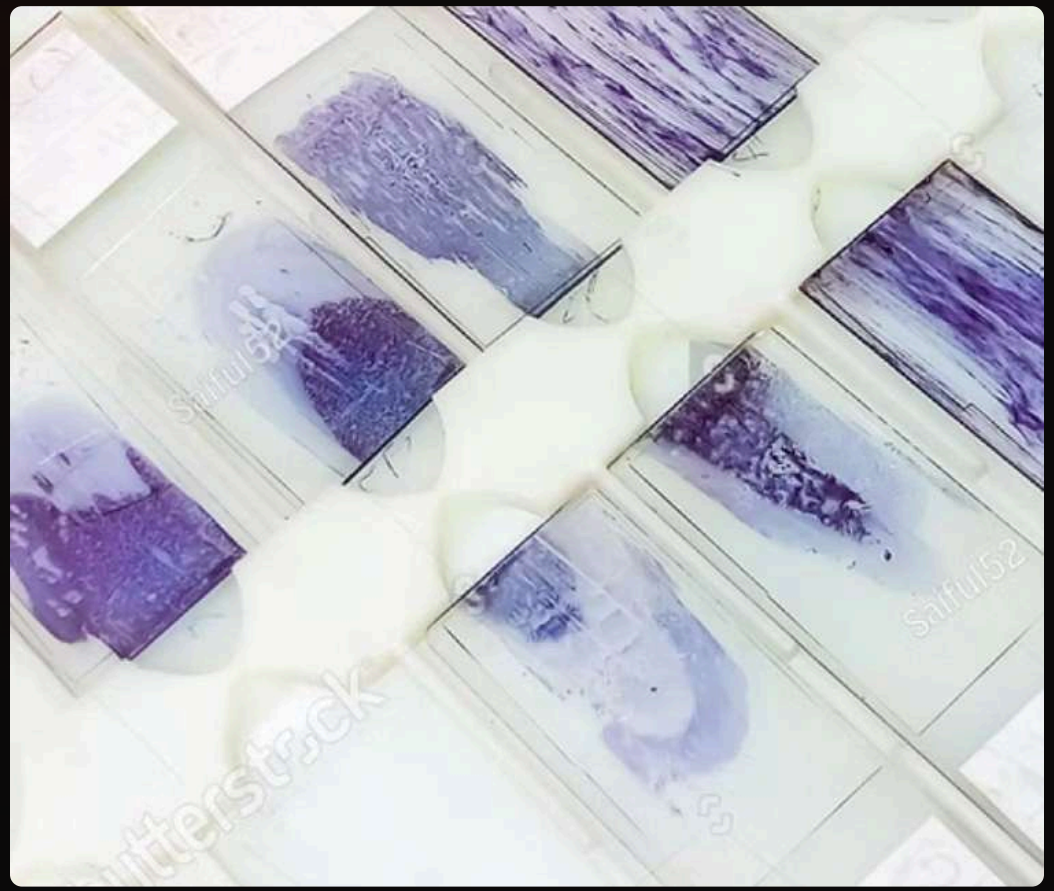

Origine & structure

Images microscopiques de coupes colorectales, colorées H&E, numérisées puis découpées en **patches indépendants de 28×28 pixels**. Aucune information de position globale n'est conservée.

Implication analytique

L'information discriminante repose sur des **motifs locaux de texture et d'intensité**, et non sur des relations spatiales à grande échelle entre patches.

Made with GAMMA

Distribution des classes & Statistiques de Pixels.

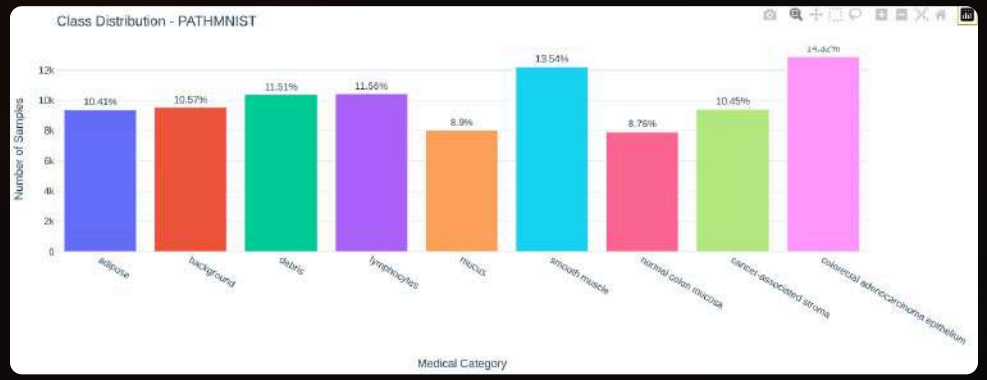

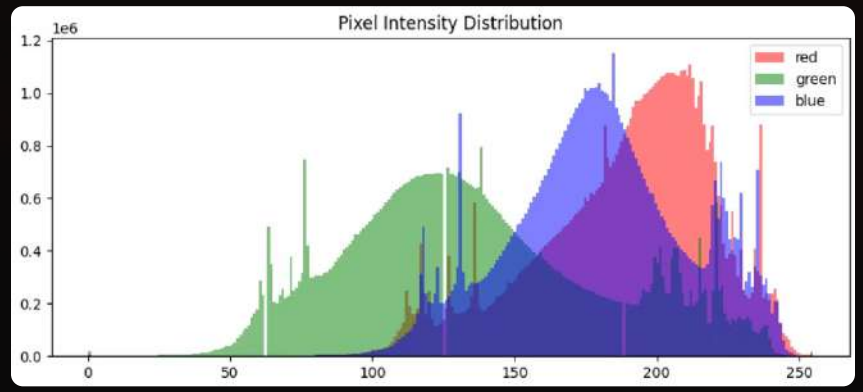

On ne remarque pas de fort déséquilibre de classe , Les performances dépendent surtout :

- de la **difficulté intrinsèque des classes**
- des **similarités visuelles**

Concernant la distribution de l'intensité des pixels on observe:

- Un **Biais couleur très fort (rouge/violet).**
- Les distributions sont reserrées avec peu de variance. On a un faible contraste global.

Made with GAMMA

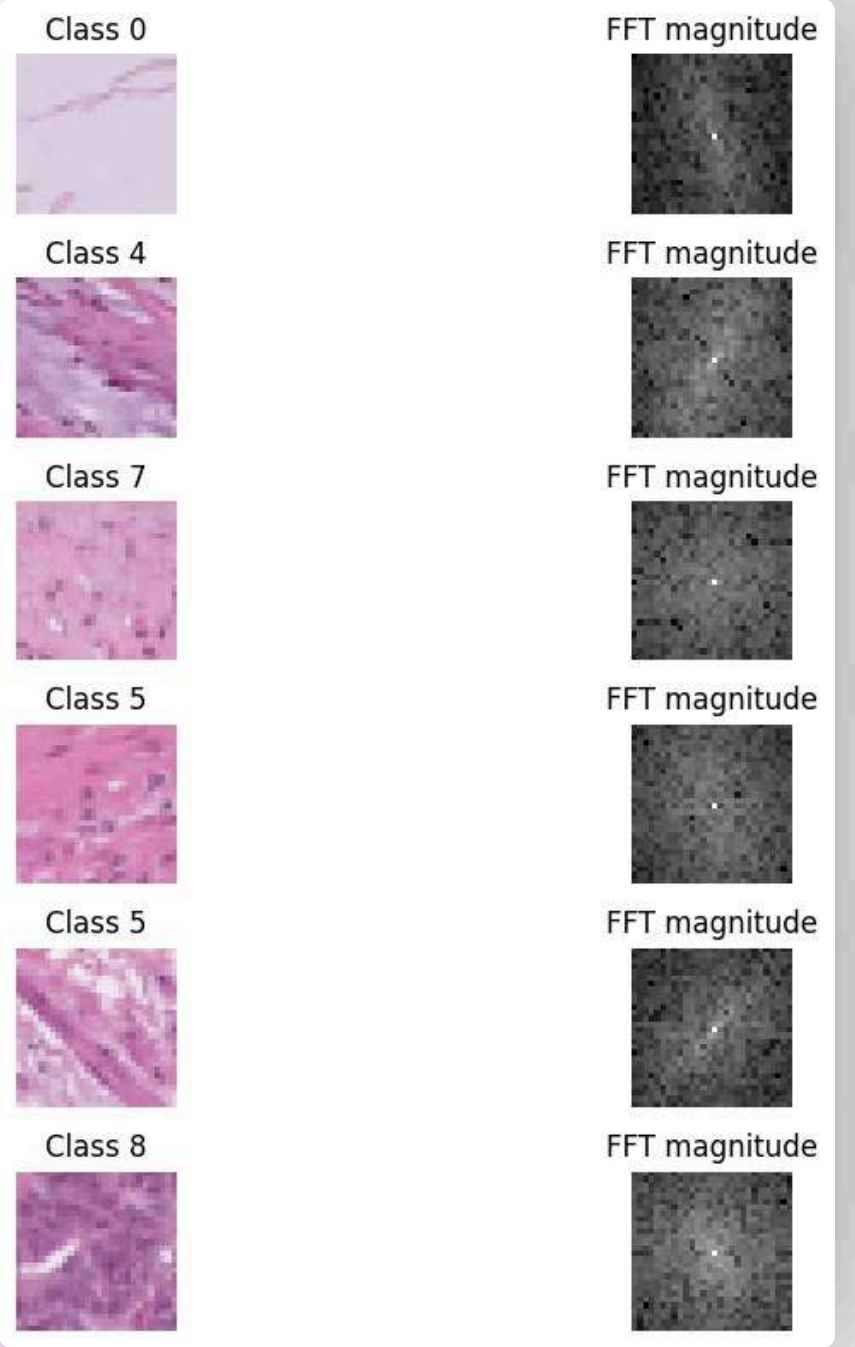

Analyse du Contenu Fréquentiel

Spectre diffus

Énergie répartie sur toutes les fréquences, sans pic dominant ni structure directionnelle marquée.

Hautes fréquences significatives

Décroissance progressive sans chute brutale : les détails fins et variations locales conservent une contribution importante.

Pas de forme globale

Absence de motifs périodiques ou réguliers — l'information est distribuée à travers les échelles, sans organisation dominante.

Ces observations confirment que la discrimination entre classes repose sur des **structures texturales complexes à petite échelle** plutôt que sur des formes globales.

Made with GAMMA

Similarité Inter-classes & Difficulté de Séparation

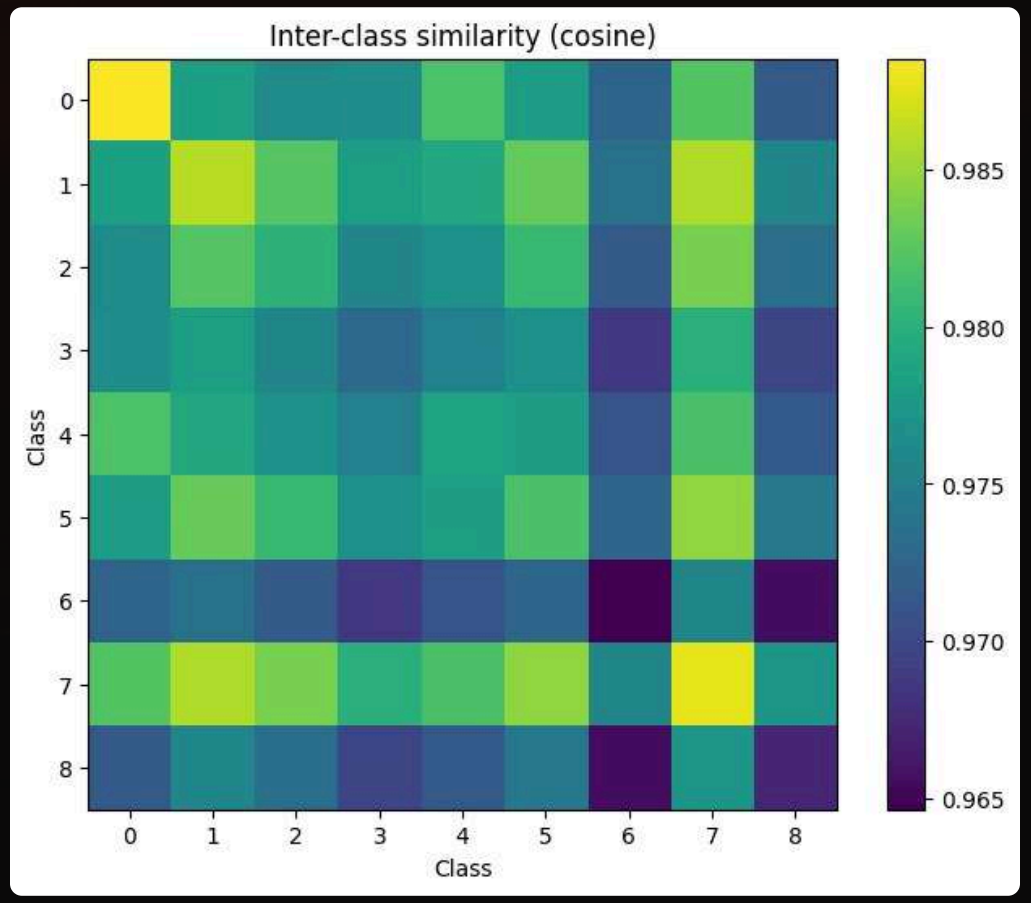

Similarité cosinus sur vecteurs aplatis

Les 9 classes occupent un **espace pixel très rapproché**, avec des valeurs de similarité cosinus globalement élevées. La classe 7 se distingue par son ambiguïté vis-à-vis de plusieurs catégories.

Conséquence directe : les caractéristiques globales simples sont insuffisantes. Les modèles doivent apprendre des **embeddings internes discriminants**, capturant des motifs locaux subtils inaccessibles à une comparaison directe de pixels.

Made with GAMMA

MODÈLE 1 — BASELINE

MLP : Multi-Layer Perceptron

Architecture

Images aplaties en vecteurs de **2 352 dimensions** → 3 couches linéaires (fc1, fc2, fc3) avec BatchNorm1d, ReLU et Dropout (p=0.2). **671 497 paramètres.**

Résultat

Accuracy test : **60.06%**. Confusion marquée entre *normal colon mucosa* et *colorectal adenocarcinoma epithelium* (288 cas), deux classes morphologiquement proches.

Limite fondamentale

Aplatissement

Détruit toute structure spatiale dès l'entrée du réseau.

Combinaisons globales

Le MLP apprend des intensités globales, pas des voisinages locaux.

Rôle pédagogique

Valide comme baseline, mais indique clairement le besoin d'un biais inductif spatial.

Made with GAMMA

MODÈLE 2 — CNN

CNN : Exploitation de la Structure Spatiale

Architecture

Blocs **Conv2D → ReLU → MaxPooling**, filtres 3×3, canaux croissants (32→64→128). Couches FC + Dropout en sortie. Entraînement avec Cross-Entropy et Adam.

Performances

Accuracy : **~86%** — gain majeur par rapport au MLP. La **data augmentation** (rotations, symétries) n'améliore l'accuracy que de +0.3 pt, mais stabilise significativement les courbes de validation.

Le biais inductif de **localité** est essentiel ici : les filtres convolutionnels détectent des motifs texturaux indépendamment de leur position, ce qui est parfaitement adapté aux images histologiques.

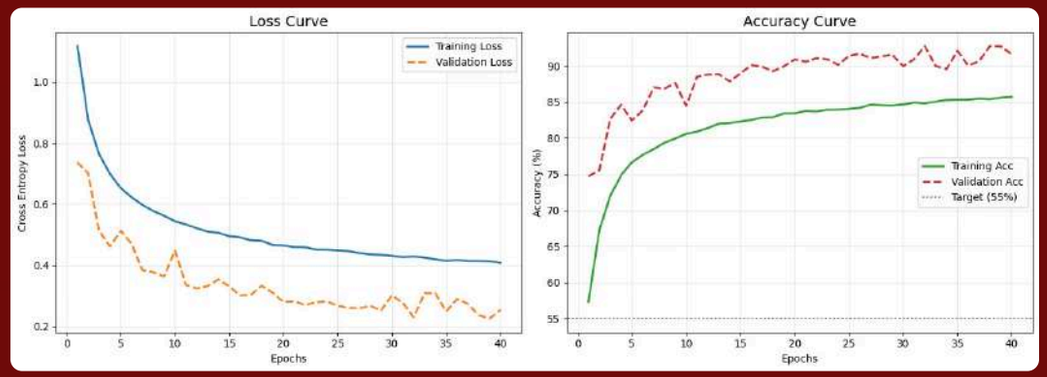

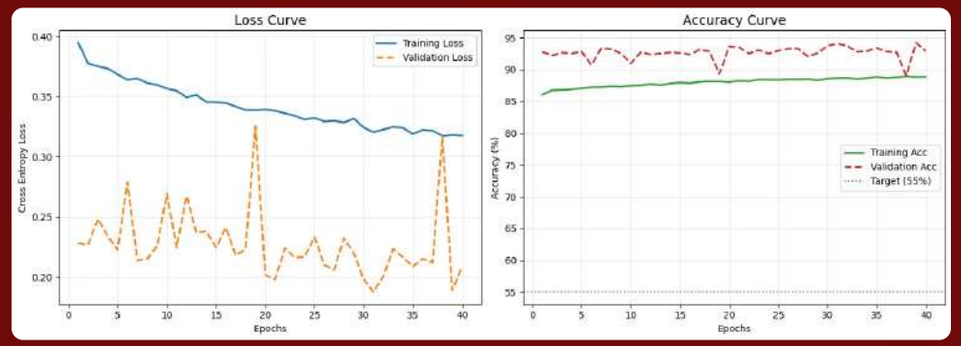

Made with GAMMA

MODÈLE 3 — RESNET18

ResNet18 : Transfer Learning & Connexions Résiduelles

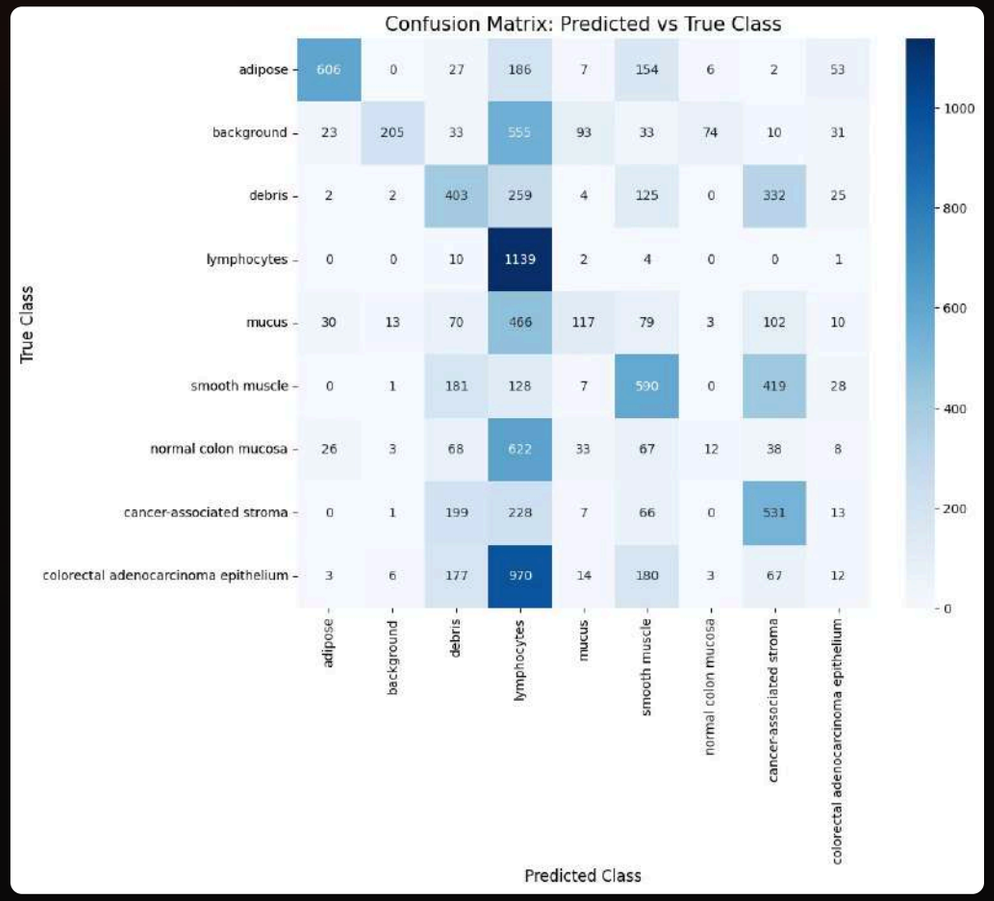

Résultats clés

- Accuracy **supérieure** aux modèles précédents (98%)
- Réduction significative des confusions entre classes proches
- **Recall élevé sur la classe 8** — critère déterminant en contexte médical (minimisation des faux négatifs)

Avantage mécanique

Les *skip connections* combinent représentations locales (couches superficielles) et abstractions globales (couches profondes), particulièrement adaptées à la hiérarchie d'échelles des images histologiques.

	CNN	ResNet
FN cancer (classe 8)	111 ❌	58 ✅
FN stroma (classe 7)	271 ❌	242 ✅
stabilité globale	moyenne	meilleure

Made with GAMMA

MODÈLE 4 — VIT

Vision Transformer : Attention Globale

Configuration SimpleViT

Patch size 7

16 patches par image, projetés en dim. 128

4 couches Transformer

8 têtes d'attention, FFN dim. 256

Token [CLS]

Résume l'information globale pour la classification finale

544 137 paramètres — ≈5.7× le CNN.

Résultat inattendu sur le positional encoding

Interprétation : en faible résolution, la **position absolue des structures** est moins informative que les motifs locaux de texture. L'encodage positionnel peut introduire du bruit plutôt qu'un signal utile.

Avec positional encoding

Accuracy test : **71.20%**

Sans positional encoding

Accuracy test : **74.99%** (+3.79 pts)

Made with GAMMA

Grad-CAM : Interprétabilité des Décisions

Méthode

Grad-CAM cible la **dernière couche convolutionnelle du ResNet18**. Les gradients de la classe prédite pondèrent les cartes de caractéristiques, produisant une heatmap superposée à l'image d'origine.

Enseignements

- Le modèle se focalise sur des **régions localement pertinentes**, cohérentes avec la structure histologique
- Sur les images *mal classées*, il regarde souvent **au bon endroit** — mais interprète incorrectement des motifs texturaux ambigus partagés entre classes
- Dans un contexte médical, cet outil renforce la **transparence et la confiance** dans les prédictions

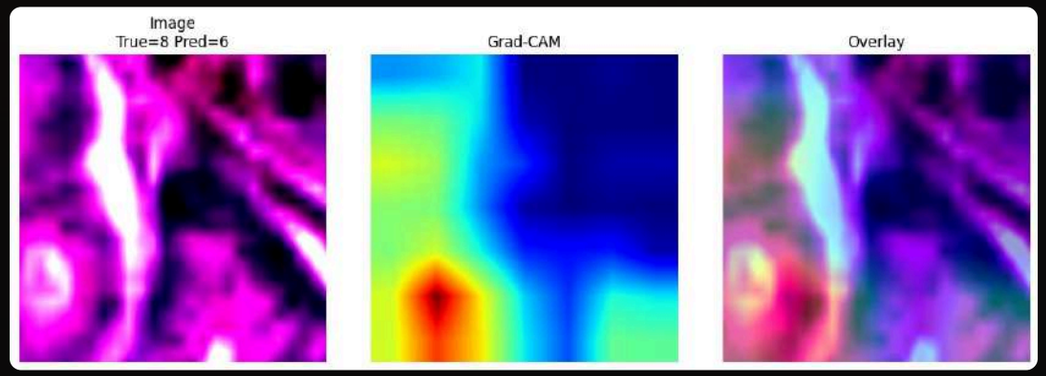

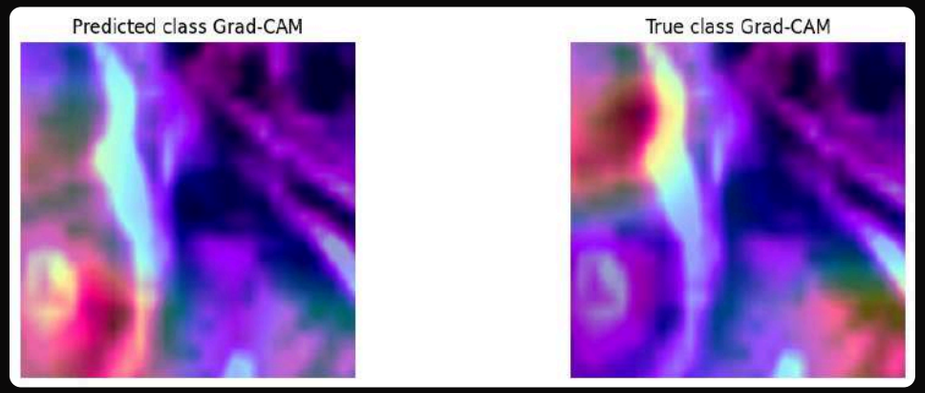

Made with GAMMA

Résultats

Voici les **valeurs relevées pour la classe 8** (*colorectal adenocarcinoma epithelium*) pour chaque modèle.

Modèle	Accuracy test	Faux négatifs (classe 8)	Recall
MLP	60.06%	354	71.3%
CNN	86.10%	111	91.8%
ResNet18 (Full fine tuning)	98.95%	58	96.4%
ViT (patch 7)	74.99%	**217**	88%

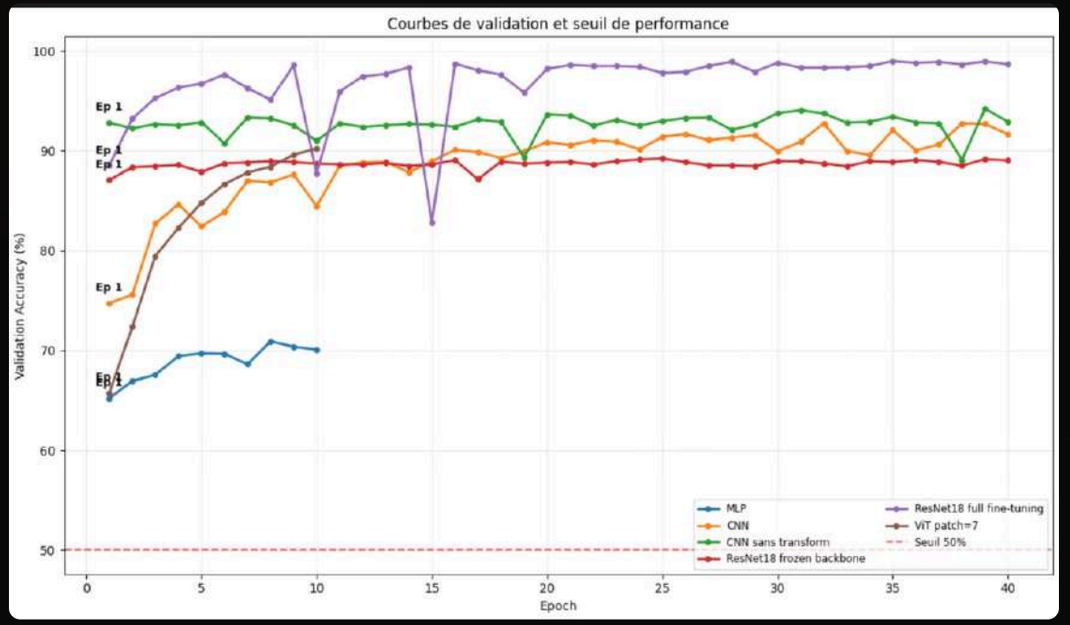

Made with GAMMA

Synthèse Comparative

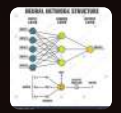

MLP – 60%

Baseline. Aucun biais spatial. Confusions sur classes proches.

CNN – ~86%

Biais inductif local. Textures bien capturées. Data augmentation = régularisateur.

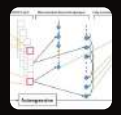

ResNet18 – meilleur ~98%

Transfer learning. Recall élevé classe 8. Combine local et global.

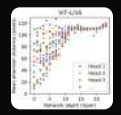

ViT – 75%

Attention globale. Sans positional encoding = +3.8 pts. Plus sensible aux données.

Le choix du modèle doit être guidé par la nature des données et surtout l'enjeu de la prediction : en histologie basse résolution, les architectures convolutionnelles restent supérieures. Les ViT expriment leur plein potentiel avec davantage de données et une résolution plus élevée, et l'element discriminant dans le choix reste la capacité à minimiser les faux negatifs.

Made with GAMMA

Point de vigilance : possible data leakage.

Au vu des courbes et accuracy trés élevée → possible data leakage.

Pas d'accés aux métadonnées sources donc impossible de prouver un leakage structurel.

→ Nous avons testé la similarité entre les ensembles. Une recherche par KNN a été réalisée entre les images de validation et d'entrainement , en utilisan tla distance euclidienne sur les pixels.

Résultat:

Images proches sur le plan chromatique mais **PAS** de duplication.

Conclusion :

On ne met pas en évidence de data leakage. Les performances élevées s'expliquent plutôt par une forte redondance visuelle et une faible variance intra-classe dans le dataset.

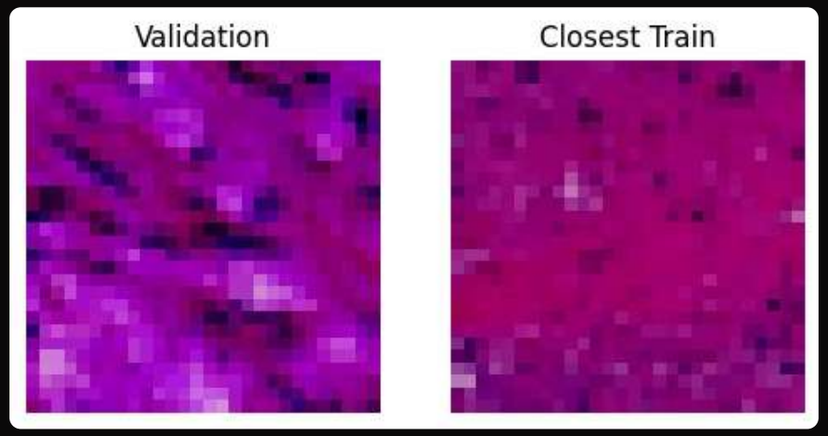

Made with GAMMA

Conclusion

👉 En histologie basse résolution :

- Les **CNN restent les plus efficaces**
- Les **ViT nécessitent plus de données et de résolution**
- Et le critère le plus important reste :

👉 **Minimiser les faux négatifs.**

👉 Un modèle à 98% d'accuracy peut être inutile s'il rate les cas critiques — en médical, le recall est plus important que l'accuracy.

Made with GAMMA